



Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP
Curso de Mestrado Profissional em Administração Pública

Classificação seletiva com modelos de linguagem na administração pública

Breno Preischardt Zanferdini de Almeida
Orientador: Prof. Dr. Marcelo Rodrigo de Souza Pita

Brasília-DF
2027

BRENO PREISCHARDT ZANFERDINI DE ALMEIDA

Classificação seletiva com modelos de linguagem na administração pública

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Área de concentração: Ciência de Dados e Inteligência Artificial

Orientador(a): Prof. Dr. Marcelo Rodrigo de Souza Pita

ALMEIDA, Breno Preischardt Zanferdini de

Classificação seletiva com modelos de linguagem na administração pública / Breno Preischardt Zanferdini de Almeida. – Brasília: IDP, 2027.

00 p.

Inclui bibliografia.

Trabalho de Conclusão de Curso (Dissertação) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, Curso de Mestrado Profissional em Administração Pública, Brasília, 2027.

Orientador: Prof. Dr. Marcelo Rodrigo de Souza Pita.

1. Inteligência artificial. 2. Modelos de linguagem. 3. Administração pública. I. Título.
CDD: a definir

Ficha catalográfica elaborada pela Biblioteca Ministro Moreira Alves
Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP

BRENO PREISCHARDT ZANFERDINI DE ALMEIDA

Classificação seletiva com modelos de linguagem na administração pública

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Área de concentração: Ciência de Dados e Inteligência Artificial

Orientador(a): Prof. Dr. Marcelo Rodrigo de Souza Pita

Brasília, a definir.

Banca Examinadora

Prof. Dr. Marcelo Rodrigo de Souza Pita
Orientador

A definir
Examinador

A definir
Examinador externo

RESUMO

Modelos de linguagem de grande escala vêm sendo usados na administração pública para classificar documentos, mas não eliminam o erro, e a sua adoção exige distinguir os casos em que a classificação automática é confiável daqueles em que a revisão humana continua necessária. Esta dissertação investiga em que medida sinais de incerteza produzidos pelos próprios modelos permitem decidir quando aceitar automaticamente uma classificação e quando encaminhá-la a uma pessoa. A fundamentação apoia-se na teoria da classificação seletiva, que troca cobertura por acurácia, e na literatura sobre autoavaliação e calibração de modelos de linguagem. A pesquisa, quantitativa e aplicada, compara a classificação proposta pelos modelos com uma classificação oficial atribuída por especialistas a uma base do setor público e avalia cada sinal por meio de curvas risco-cobertura. Espera-se oferecer um critério verificável de encaminhamento à revisão humana, coerente com a exigência de supervisão proporcional ao risco.

Palavras-chave: Inteligência artificial generativa. Modelos de linguagem de grande escala. Classificação seletiva. Quantificação de incerteza. Supervisão humana.

ABSTRACT

Large language models are being used in public administration to classify documents, yet they do not eliminate errors, and their adoption requires distinguishing the cases in which automated classification is reliable from those in which human review remains necessary. This dissertation investigates to what extent uncertainty signals produced by the models themselves make it possible to decide when a classification can be accepted automatically and when it should be referred to a person. The theoretical framework draws on selective classification, which trades coverage for accuracy, and on the literature on self-evaluation and calibration of language models. The research, quantitative and applied, compares the classification proposed by the models with an official classification assigned by experts to a public-sector document base and evaluates each signal through risk-coverage curves. It aims to provide a verifiable criterion for referral to human review, consistent with the requirement of oversight proportional to risk.

Keywords: Generative artificial intelligence. Large language models. Selective classification. Uncertainty quantification. Human oversight.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo de uma classificação seletiva	11
--	----

LISTA DE TABELAS

Tabela 1 – Sinais de autoavaliação de modelos de linguagem.....	12
---	----

LISTA DE ABREVIATURAS E SIGLAS

IA	Inteligência Artificial
IDP	Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa
LLM	<i>Large Language Model</i> (modelo de linguagem de grande escala)

SUMÁRIO

1	INTRODUÇÃO.....	10
2	REFERENCIAL TEÓRICO.....	11
3	PROCEDIMENTOS METODOLÓGICOS	13
4	ANÁLISE E DISCUSSÃO.....	14
5	CONSIDERAÇÕES FINAIS.....	15
	REFERÊNCIAS	16

1 INTRODUÇÃO

Modelos de linguagem de grande escala passaram a ser usados na administração pública para classificar documentos, uma tarefa repetitiva e de alto volume em que a automação promete ganho de escala. Esses modelos, porém, não eliminam o erro, e um erro de classificação em um processo público pode afetar a recuperação de informações, a consistência das decisões e a prestação de contas. A questão prática deixa de ser se o modelo acerta em média e passa a ser em quais casos a sua resposta pode ser aceita sem conferência.


Esta pesquisa parte da pergunta: em que medida sinais de incerteza produzidos pelos próprios modelos de linguagem permitem decidir quando uma classificação pode ser aceita automaticamente e quando deve ser encaminhada à revisão humana? A pergunta aplica ao contexto da administração pública a ideia de classificação seletiva, em que o classificador pode abster-se nos casos duvidosos (EL-YANIV; WIENER, 2010). O objetivo geral é avaliar se esses sinais sustentam um mecanismo de encaminhamento que reduza o erro entre os casos aceitos sem transferir todo o trabalho de volta às pessoas.

2 REFERENCIAL TEÓRICO

A classificação com opção de rejeição, chamada de classificação seletiva, troca cobertura por acurácia: ao recusar os casos mais duvidosos, o classificador reduz o erro entre os casos que decide. El-Yaniv e Wiener (2010) chamam esse compromisso de troca risco-cobertura e o tomam como objeto central da teoria. A Figura 1 resume o mecanismo: um classificador propõe a classe e uma função de seleção decide se a proposta é aceita ou encaminhada a uma pessoa. Geifman e El-Yaniv apresentam a motivação dessa linha de pesquisa nos seguintes termos:

While self-awareness remains an illusive, hard to define concept, a rudimentary kind of self-awareness, which is much easier to grasp, is the ability to know what you don't know, which can make you smarter. The subfield dealing with such capabilities in machine learning is called selective prediction (also known as prediction with a reject option), which has been around for 60 years. (GEIFMAN; EL-YANIV, 2017, p. 1)

Figura 1 – Fluxo de uma classificação seletiva



Fonte: Elaborado pelo autor com base em Geifman e El-Yaniv (2017).

Para que a função de seleção funcione com modelos de linguagem, é preciso que eles carreguem algum sinal confiável sobre a própria chance de erro. Kadavath *et al.* (2022) mostram que modelos maiores são bem calibrados em questões de múltipla escolha e de verdadeiro ou falso quando recebem o formato adequado, e propõem dois sinais de autoavaliação, descritos na Tabela 1. Esses sinais são candidatos naturais à função de seleção da Figura 1, desde que se verifique se continuam informativos fora dos conjuntos de teste em que foram propostos.

Tabela 1 – Sinais de autoavaliação de modelos de linguagem

Sinal	Pergunta que responde	Quando é obtido
P(True)	A resposta proposta está correta?	Depois de o modelo responder
P(IK)	O modelo sabe responder?	Antes de qualquer resposta

Fonte: Elaborado pelo autor com base em Kadavath et al. (2022).

3 PROCEDIMENTOS METODOLÓGICOS

A pesquisa adota abordagem quantitativa e caráter aplicado. Modelos de linguagem classificarão documentos de uma base do setor público que já possui uma classificação oficial, atribuída por especialistas, que servirá de referência para medir acertos e erros. Para cada documento serão registrados a classe proposta pelo modelo e os sinais de incerteza associados a ela.

A avaliação seguirá as medidas próprias da classificação seletiva: para cada regra de encaminhamento, calcula-se a cobertura, isto é, a fração de casos aceitos automaticamente, e o risco, isto é, a taxa de erro entre esses casos. Comparar as curvas risco-cobertura dos diferentes sinais permitirá dizer qual deles separa melhor os casos que podem dispensar a revisão humana.

4 ANÁLISE E DISCUSSÃO

Este capítulo apresentará o desempenho dos modelos na tarefa de classificação e a qualidade de cada sinal de incerteza como função de seleção. A análise começará pela acurácia global, que serve de linha de base, e seguirá para as curvas risco-cobertura, que mostram quanto do erro pode ser evitado a cada nível de revisão humana.

A discussão confrontará os resultados com a literatura de classificação seletiva e de autoavaliação de modelos de linguagem, verificando se os sinais que funcionam em conjuntos de teste internacionais mantêm o mesmo comportamento em documentos da administração pública brasileira.

5 CONSIDERAÇÕES FINAIS

As considerações finais retomarão a pergunta de pesquisa e dirão se os sinais de incerteza dos modelos de linguagem sustentam, na prática, um mecanismo de encaminhamento entre a aceitação automática e a revisão humana, indicando com que cobertura e com que risco residual isso é possível.

Espera-se que o trabalho ofereça aos gestores públicos um critério verificável para decidir quando confiar na classificação automática, alinhado à exigência de supervisão humana proporcional ao risco, e que aponte os limites do mecanismo e os caminhos para pesquisas futuras.

REFERÊNCIAS

GEIFMAN, Yonatan; EL-YANIV, Ran. **Selective classification for deep neural networks**. arXiv:1705.08500. 2017. Disponível em: <https://arxiv.org/abs/1705.08500>. Acesso em: 3 out. 2026.

KADAVATH, Saurav *et al.* **Language models (mostly) know what they know**. arXiv:2207.05221. 2022. Disponível em: <https://arxiv.org/abs/2207.05221>. Acesso em: 3 out. 2026.

EL-YANIV, Ran; WIENER, Yair. On the foundations of noise-free selective classification. **Journal of Machine Learning Research**, v. 11, p. 1605–1641, 2010. Disponível em: <https://jmlr.org/papers/v11/el-yaniv10a.html>. Acesso em: 3 out. 2026.